

基于遗传算法和优化模型的 NIPT 的时点选择问题研究

在当前无创产前监测的医学背景下，如何基于孕妇生理指标确定最佳检测时间以降低误诊风险、提高筛查可靠性成为关键问题。本文围绕 Y 染色体浓度与各指标建立了稳健回归关系模型；通过 GA 遗传算法划分 BMI 分组与最佳检测点，并分析误差影响；建立 Logistic Regression 女胎异常模型，并对模型进行敏感性分析。

针对问题一，本文基于 Y 染色体浓度与其他变量的相关特性，构建了稳健回归模型。首先对数据进行转换、编码与统计分析，通过 AD 正态检验发现数据不符合正态分布，选择斯皮尔曼相关系数分析，得出：Y 染色体与检验抽血次数、X 染色体浓度显著中等正相关；与 18 号染色体 Z 值，参考基因组上比对比例显著弱负相关；GC 含量和生产次数近乎不相关不显著；与其余变量均相关性极弱但显著。通过分析筛选，得到 Y 染色体浓度与孕妇年龄(x_1)、身高(x_2)、体重(x_3)、检验抽血次数(x_4)、检验孕周(x_5)、孕妇 BMI(x_6) 关系模型为 $z = -0.287 - 0.0009x_1 + 0.0029x_2 - 0.0031x_4 - 0.0033x_5 + 0.0059x_6$ 。并对模型结果显著检验，检验模型整体的拟合效果。

针对问题二，本文将 BMI 组间划分与最佳 NIPT 时点确定作为优化变量，将 BMI 区间划分为三组并构建分段风险代价函数；同时，通过构建核平滑曲线对特定孕周的检测成功概率进行预测，以期望风险为约束条件，将风险加权总和最小化作为最终总体优化目标。采用遗传算法(GA)对 BMI 分组及最佳 NIPT 时点进行优化，得到四个 BMI 分组阈值点 29.960, 31.158, 32.662 和 34.442，除第二组划分的最佳检测时点为 18.3 周外，其余均为 9 周。此外，在 Y 染色体浓度中引入正态噪声，利用蒙特卡洛模拟分析误差影响，结果表明：误差会导致达标率下降，增加部分孕妇的潜在风险；在高 BMI 孕妇群体中，误差会放大误判概率，进而迫使模型延迟检测时点。

针对问题三，将年龄、身高、体重等多项影响因素设为特征向量，利用问题二的遗传算法(GA)对 BMI 进行分组，确定 30.279, 31.193, 31.707, 32.563 四个阈值点。选择多因素预测模型预测达标概率，设立平均风险函数进而确定三组最佳孕周分别为 19.10 周、21.20 周、13.30 周，12.60 周和 18.94 周假设误差检测服从正态分布，设立风险预期，利用遗传算法(GA)寻求最小平均风险值为 0.0765。风险区间的波动反映检测误差（如测序失败、数据噪声）可能导致部分样本未达标，使最佳 NIPT 时点检测失败概率上升。

针对问题四，本文以女胎孕妇的 21 号、18 号和 13 号染色体非整倍体检测结果（AB 列）作为判定女胎是否异常的标准，选取 X 染色体及上述染色体的 Z 值、GC 含量、读段数及相关比例、BMI 等因素作为自变量。在对数据进行标准化处理以消除量纲影响后，构建 Logistic Regression 模型用于女胎异常的预测，求解得到模型对应的系数，并对该女胎异常判定方法进行灵敏度分析与综合评估。

关键词：无创产前检测，稳健回归，遗传算法，蒙特卡洛模拟，逻辑回归

一、问题重述

1.1 问题背景

无创产前检测(NIPT)^[1-4]是一种基于孕妇外周血中胎儿游离 DNA(cfDNA)的高通量测序技术,用于筛查胎儿染色体非整倍体异常(如 21-三体、18-三体、13-三体)。其核心原理是通过分析胎儿性染色体(男胎 Y 染色体或女胎 X 染色体)的浓度比例,判断检测结果的可靠性。临床研究表明,男胎 Y 染色体浓度需 $\geq 4\%$ 才能保证检测准确性,而检测时机的选择(孕周 10~25 周)直接影响结果的稳定性与早期干预的有效性。

研究表明,男胎的 Y 染色体浓度与孕妇的孕周数及身体质量指数(BMI)密切相关。由于孕妇的年龄、BMI、孕情等因素存在个体差异,简单采用统一的时间点可能导致部分检验结果不准确,影响后期干涉举措。此外,女胎异常的判定需综合 Z 值、GC 含量、读段数等多维指标,但目前缺乏系统性的判定标准。因此,如何基于孕妇的 BMI、孕周及其他生理指标,科学地确定最佳 NIPT 检测时间,以降低误诊风险并提高早期筛查的可靠性,成为当前研究的关键问题^[16]。




图 1 问题背景图

1.2 问题提出

问题一：分析胎儿 Y 染色体浓度与孕妇孕周数、身体质量指数(BMI)等关键指标的相关特性,建立统计模型量化其关系,并通过显著性检验验证模型可靠性。

问题二：基于 BMI 对男胎孕妇进行合理分组,确定各组的最佳 NIPT 检测时点,使得潜在临床风险最小化,并评估检测误差对分组结果的敏感性。

问题三：综合考虑孕妇身高、体重、年龄等协变量,结合检测误差和 Y 染色体浓度达标比例,对男胎孕妇群体进行精细化分组,构建风险最小化的最佳检测时点决策模型。同时,需分析检测误差(如测序失败、数据噪声)对分组和时点

选择的影响。

问题四：针对女胎孕妇，以 21 号、18 号、13 号染色体非整倍体检测结果为依据，结合 X 染色体 Z 值、GC 含量、读段数比例等特征，建立胎儿异常的数学判定模型。




图 2 思路框架图

二、模型假设

- (1) 假设所带有时间序列的参数(末次月经，检测日期)与风险值，胎儿是否异常相关性低，可忽略时间序列的影响。
- (2) 假设检测误差服从真正态分布。
- (3) 假设 Y 染色体浓度与各自变量的关系模型只需反应相关的关系趋势，不用于预测
- (4) 假设少量异常值能反应特殊群体特性，例如 bmi 接近 50 的孕妇。

三、符号说明

含义	符号	含义	符号
Anderson-Darling 检验统计量	A^2	男胎孕妇期望风险加权和	$W(\tau, t)$
样本容量	n	落在第 k 组的样本数量	n_k
样本数据按升序排列后的第 i 个观测值	x_i	最小风险加权总和	$\min_{\tau, t} W(\tau, t)$
假设分布的累积分布函数	$F(x_i)$	原本风险	R_i
稳健回归方程因变量（Y 染色体浓度）	y	误差影响下的风险均值	$\hat{R}_i$
稳健回归方程截距项（基线浓度）	β_0	蒙特卡洛模拟次数	N_{sim}
稳健回归方程第 i 个自变量	x_i	第 j 个孕妇 Y 染色体浓度	y_j
第 i 个自变量所对应的回归系数	β_i	第 j 个孕妇的特征向量	x_j
服从独立分布的随机误差	ϵ	第 j 个孕妇的检测孕周	W_j
胎儿 Y 染色体浓度	z	达标指标	D_j
孕妇孕周数	x	BMI 分组	g

孕妇 BMI	y	达标指示函数	S_j
决定系数	R^2	达标概率	p_j
均方根误差	$RMSE$	第 i 组潜在风险	R_i
男胎孕妇 BMI 划分区间个数	K	正态分布方差	σ^2
划分阈值分组点	τ	平均风险	R_{avg}
不同 BMI 推荐孕周	t	误差达标指标	S_j^{errpr}
风险函数	$R(t)$	第 i 组风险预期	R_i^{error}
成功率函数	$C(t)$	最小平均风险值	$\min_{\{b_1, b_2, b_3\}} R_{avg}^{error}$
检测达标指标	$Hit_i(\sigma)$	第 j 组平均孕周	T_j
第 i 个孕妇的孕周	w_i	最佳 NIPT 时点	T_i^{best}
第 i 个孕妇胎儿 Y 染色体浓度	Y_i	女胎异常概率	$P(X = 1)$
带宽	h	逻辑回归方程截距	b_0
核函数	K_h	女胎孕妇第 n 项检测数据	X_n
期望风险	E_k	第 n 项检测数据的回归系数	b_n

四、问题一模型的建立与求解

4.1 问题分析

问题一的核心是对胎儿 Y 染色体浓度与孕妇各指标进行相关特性分析，建立关系模型并验证模型可靠性。首先对数据进行预处理，并初步统计分析数据；其次，对数据进行 AD 正态性检验，根据非正态的检验结果判断使用斯皮尔曼相关性分析，对各变量的相关性与显著性进行分析；最后，考虑到数据有部分极端异常值代表着部分特殊群体的真实情况，保留异常值选取稳健最小二乘法，通过 LAR 稳健化处理，建立 Y 染色体浓度与其他变量的关系模型并验证。




图 3 问题一流程图

4.2 模型准备

4.2.1 格式转换

（1）孕周格式标准化

附件原始数据中孕周记录为“周数+天数”，不同单位混合会引入计算偏差。因此，本文统一转换为十进制周数便于后续数值计算和模型输入。转换步骤如下：
STEP1: 提取原始数据中的周数（整数部分）和天数（小数部分）
STEP2: 计算：十进制周数 = 周数 + 天数/7
STEP3: 对所有样本执行相同转换，生成新变量“孕周（十进制）”

（2）变量编码

将 IVF 妊娠的自然怀孕编号 2，IUI（人工授精）编号 1，IVF（试管婴儿）编号 3；将染色体的非整倍体的无疾病部分（空白）编号 0，有疾病的部分（T13,T18,T21）编号 1；将怀孕次数≥3 的部分编号 3，其余编号不变；将胎儿是

否健康的健康编号 1，不健康编号 0。

4.2.2 多变量直方图与矩阵散点图的分析

多变量直方图与矩阵散点图见附件，Y 染色体浓度孕周数与 BMI 的散点图在散点图矩阵中，Y 染色体浓度与孕妇 BMI 的散点大致分布于矩阵的左下角区域，分布较为分散，无明显线性趋势，但图中未呈现明显负相关，可能表明该数据集集中孕妇 BMI 对 Y 染色体浓度的干扰较弱。在 Y 染色体浓度与检测孕周的散点图中，数据点呈现轻微正相关的趋势。由于孕周是影响 Y 染色体浓度检测准确性的关键因素，因此 Y 染色体浓度随孕妇孕周的增加而升高符合预期。

4.2.3 异常值检验

箱线图（Box Plot）能直观、简洁地展示数据的分布特征与异常值。为防止数据异常值扭曲统计检验和模型结果，本文采用箱线图对数据进行异常值检验与初步分析，箱线图中值线为实线均值线为虚线。




图 4 各变量箱线图

由图四可以初步分析得：孕妇 BMI 数据分布广，主要分布于 30-34，且存在少量 20 的异常低值和 45 以上异常高值，但反映了特殊群体的真实情况；Y 染色体浓度集中于 0.07 附近值；孕周数据集中于 16-17 周且波动性小。

4.3 描述性统计分析

描述性统计分析的核心是将原始数据转化为直观、可理解的信息，概括数据的基本特征。为便于后续深入分析，对检测孕周、孕妇 BMI 等变量与 Y 染色体浓度进行描述性统计分析，见附录表 1。

由描述性统计分析表可以看出，测序指标（如 GC 含量、基因组比对比例）在合理范围内，数据可靠；研究对象以年轻（28.94 岁）、超重（BMI 32.29）孕妇为主，存在高 BMI 极端值；对于异常值，选择稳健方法制异常值干扰。

4. 4 正态性检验

4.4.1 Anderson-Darling 检验

(1)检验方法

为验证检测孕周、孕妇 BMI 及 Y 染色体浓度三个关键指标的分布特征，确保后续统计分析方法选择的合理性，采用（见式 1）Anderson-Darling（AD）正态性检验^[5]对数据分布形态进行定量评估。具体公式如下：

$$A^2 = -n - \frac{1}{n} \sum_{i=1}^n (2i - 1) [\ln F(x_i) + \ln(1 - F(x_{n+1-i}))] \tag{1}$$

其中A²代表 Anderson-Darling 检验统计量，值越大，样本数据与假设分布的拟合度越差；*n* 为样本容量（数据点的数量）。*x_i*样本数据按升序排列后的第*i*个观测值；F(*x_i*)代表假设分布的累积分布函数（CDF）。

AD 检验通过计算样本数据与理论正态分布的偏离程度（AD 统计量），并与不同显著性水平下的临界值比较，判断数据是否服从正态分布。检验规则如下：

若 AD 统计<临界值，则接受正态分布假设；

若 AD 统计量≥临界值，则拒绝正态分布假设，认为数据显著偏离正态分布。

(2)检验结果

表 1 Anderson-Darling 检验

变量	AD 统计量	1%临界值	变量	AD 统计量	1%临界值
年龄	7.60	1.09	18 号染色体 Z 值	1.91	1.09
身高	3.26	1.09	21 号染色体 Z 值	0.43	1.09
体重	10.28	1.09	X 染色体 Z 值	3.75	1.09
检测抽血次数	53.64	1.09	Y 染色体 Z 值	7.23	1.09
检测孕周	29.84	1.09	Y 染色体浓度	4.79	1.09
孕妇 BMI	11.90	1.09	X 染色体浓度	2.56	1.09
原始读段数	3.21	1.09	13 号染色体 GC 含量	6.72	1.09
参考基因组比对的比例	29.06	1.09	18 号染色体 GC 含量	5.01	1.09
重复读段的比例	5.13	1.09	21 号染色体 GC 含量	2.93	1.09
GC 含量	3.33	1.09	被滤掉读段数比例	3.93	1.09
13 号染色体 Z 值	1.27	1.09	生产次数	181.71	1.09

由 AD 检验的统计结果(见表一)可得,Y 染色体浓度的 AD 统计量(4.7920)显著高于所有显著性水平下的临界值；孕妇 BMI 的 AD 统计量（11.9033）为三个指标中最高，且偏度（0.864）和峰度（2.649）显示数据呈尖峰正偏分布；检验孕周的 AD 统计量（29.8399）最大，数据离散度较高（标准差 4.076）。可见三种变量均不符合正态分布。

4.4.2 Q-Q 图检验

Q-Q 图是一种通过比较两个概率分布的分位数对这两个概率分布进行比较的概率图方法。数据量非常大的情况下，检验样本数据是否符合正态分布，要看 Q-Q 图上的点是否近似在一条直线上。




图 5 Y 染色体浓度 Q-Q 图

通过 Q-Q 图（如图 5）我们可以直观地 Y 染色体浓度的数据不符合正态分布。结合 AD 检验与 Q-Q 图可得，变量指标均不服从正态分布，传统参数检验方法可能导致结果偏倚，故选择斯皮尔曼相关系数衡量 Y 染色体浓度与孕妇孕周、BMI 的相关关系。

4.5 绘制散点图

通过 Python 软件绘制胎儿 Y 染色体浓度与孕妇的孕周数和 BMI 关系的 3D 散点图，将三个变量同时纳入一个视觉框架，便于直观分析数据点在三维空间中的分布。




图 6 3D 散点图

散点图（见图 6）显示 Y 染色体浓度在 BMI 30-35、孕周 20-25 区间形成浅

绿色“浓度高峰带”，该非线性特征无法通过相关系数捕捉，为分组优化提供新依据。该散点图直观展示了孕妇 BMI 与 Y 染色体浓度的负相关，散点图的低浓度点密集分布与 AD 检验的非正态结果一致，支持使用稳健回归处理数据。

4.6 斯皮尔曼相关性分析

利用斯皮尔曼等级相关系数^[6-8]评估检测孕周、孕妇 BMI 与 Y 染色体浓度之间的单调关系，为 NIPT 检测时点优化提供统计学依据。通过 python 软件计算斯皮尔曼相关系数，绘制热力图（图 7）：




图 7 Spearman 相关系数热力图

Y 染色体浓度与检测抽血次数呈显著中等正相关（ $r=0.323$ ， $p<0.01$ ）；与 X 染色体浓度呈较强显著正相关（ $r=0.474$ ， $p<0.01$ ）；Y 染色体浓度与年龄呈显著负相关（ $r=-0.117$ ， $p<0.01$ ）；与 18 号染色体的 Z 值（ $r=-0.178$ ， $p<0.01$ ）、在参考基因组上比对的比例（ $r=-0.159$ ， $p<0.01$ ）呈显著负相关，但相关性强度较弱。与各染色体 GC 含量和生产次数几乎无相关性，且结果不显著；其余变量均与 Y 染色体相关性极弱，但相关性显著。

4.7 稳健回归

稳健回归通过调整损失函数或算法设计，降低异常值对模型参数估计的干扰。相比于传统最小二乘法（OLS）^[9]，其目标在于提升模型在噪声数据中的表现，确保预测准确性和分析结果的可靠性。由于原始数据可能存在异常值干扰，本研究采用稳健回归方法构建模型，用于探究胎儿 Y 染色体浓度（因变量 y ）年龄（ x_1 ）身高（ x_2 ）体重（ x_3 ），检验抽血次数（ x_4 ）检验孕周（ x_5 ），孕妇 BMI（ x_6 ）

之间的定量关系。

4. 6. 1 模型建立

为了得出 Y 染色体浓度与其他自变量的关系，用多项式得出方程：

$$y = \beta_0 + \beta_1x_1 + \beta_2x_2 + \beta_3x_3 + \beta_4x_4 + \beta_5x_5 + \beta_6x_6 + \epsilon \tag{2}$$

其中， β_0 为截距项（基线浓度）； β_i 分别为对应 x_i 的回归系数； ϵ 服从独立同分布的随机误差。采用迭代重加权最小二乘法（IRLS）。

4. 6. 2 计算结果

通过 MATLAB 拟合计算得到：

表 2 各系数结果

变量	系数	标准误	t 统计量	p 值
截距	-0.287	0.27936	-1.0273	0.30451
x_1	-0.0009	0.00024	-3.7193	0.00021
x_2	0.0029	0.00172	1.6748	0.09426
x_3	-0.0031	0.00165	-1.8682	0.06201
x_4	0.0188	0.00124	15.145	4.11E-47
x_5	-0.0033	0.00034	-9.564	7.44E-21
x_6	0.0059	0.00433	1.3605	0.17394

将数据（见表 2）代入到公式中可得到胎儿 Y 染色体浓度（因变量 z ）与孕周数（自变量 x ）、孕妇 BMI（自变量 y ）的关系模型（式 6）。

$$z = -0.287 - 0.0009x_1 + 0.0029x_2 - 0.0031x_4 - 0.0033x_5 + 0.0059x_6 \tag{6}$$

4. 6. 3 模型验证

通过 Python 数据库计算模型的 F 检验（模型显著性）、决定系数（ R^2 ）、调整 R^2 （Adjusted R^2 ）、均方根误差（RMSE）以验证模型的拟合优度。

表 3 拟合优度值表

拟合优度	F 统计量	R^2	调整 R^2	RMSE	P 值
值	53.6	0.23	0.226	0.0286	5.61e-58

F 统计量为 53.6，对应的 P 值为 5.61e-58（远小于 0.05），这表明模型中自变量的整体组合对 Y 染色体浓度具有显著的统计学影响，即模型整体是有效的，并非由随机因素导致的结果； $R^2=0.23$ 表明模型可解释 Y 染色体浓度变异的 23%；调整后 $R^2=0.226$ ：考虑自由度后解释力略有下降；RMSE=0.0286 表示模型预测误差较小，拟合效果可接受。由于年龄、身高、体重、抽血次数、孕周、BMI 与预测目标（Y 染色体浓度）之间缺乏有效的线性预测关系，所以 R^2 较低，这也比较符合当前的医学研究结果。

五、问题二模型的建立与求解

5. 1 问题分析

为确定合理划分组别并的带每组的 BMI 区间与 NIPT 时点数，文章把 BMI 区间分为三组并建立分段风险代价函数，构建核平滑曲线对孕周的样本进行加权平均，来反映孕周与达标概率的关系，使用 GA 遗传算法引入约束条件并设立惩罚目标降低期望风险。为分析检测误差对结果的影响，本文在 Y 染色体浓度上引入正态噪声，并通过蒙特卡洛模拟进行敏感性分析，确保模型的稳健性。



图 8 问题二流程图

5.2 确立决策变量

针对男胎孕妇的 BMI 进行分组，设定将男胎孕妇划分为 K 个区间，则划分阈值的分组点为 $K-1$ 个，即 $\tau_1, \tau_2, \dots, \tau_{K-1}$ ，同时各组检测的 NIPT 时点有 K 个，依次对应每个 BMI 区间所推荐的孕周，分别为 $t_1, t_2, \dots, t_K$ 。

5.3 模型的建立

STEP1 风险函数

在检测胎儿健康状况的实际情况下，检测时间的早晚对治疗风险的高低有显著影响，在不同时期检测所带来的治疗窗口期缩短的风险不同。越早检测风险越小，反之越大；同时孕妇孕周越大风险越高，反之越小。在此定义早期发现（12 周以内）检测风险系数为 1，中期发现（13—27 周）检测风险系数为 3，晚期发现（28 周以后）检测风险系数为 9，设立（式 7）风险函数 $R(t)$ ，表达式如下：

$$R(t) = \begin{cases} 1, & t \leq 12 \\ 3, & 12 < t < 28 \\ 9, & t \geq 28 \end{cases} \quad (7)$$

STEP2 成功率函数

在附录的男胎监测数据中，利用核平滑的方法，选用样本数据预测男胎孕妇在孕周 t 时检测成功的概率，即设为（式 9）成功率函数 $C(t)$ ，表达式如下：

$$\text{Hit}_i(\sigma) = \mathbf{1}(Y_i \geq 0.04) \quad (8)$$

$$C(t) = \frac{\sum_i K_h(t - w_i) \text{Hit}_i}{\sum_i K_h(t - w_i)} \quad (9)$$

其中 w_i 为第 i 个孕妇的孕周， Y_i 表示 Y 染色体浓度， Hit_i 表示检测是否达标，核函数 K_h 取高斯核，带宽 $h \approx 0.7$ 周。

STEP3 期望风险

假定某 BMI 分组中男胎孕妇在孕周 t_k 检测时的（式 10）期望风险为 E_k ，其表达式如下：

$$E_k(t_k) = C(t_k) \cdot R(t_k) + (1 - C(t_k)) \cdot R(t_k + \Delta) \quad (10)$$

其中 Δ 为复检延迟，设所有男胎孕妇期望风险的加权和（式 11）为 $W(\tau, t)$ ，其表达式如下：

$$W(\tau, t) = \sum_{k=1}^K n_k \cdot W_k(t_k) \quad (11)$$

其中 n_k 为落在第 k 组的样本数量，并确立最终总体优化目标，使风险加权总和最小，即 $\min_{\tau, t} W(\tau, t)$ 。

将前面的函数方程与约束条件汇总（式 12），建立数学模型：

$$\left\{ \begin{array}{l} 20.703 \leq BMI \leq 46.875 \\ R(t) = \begin{cases} 1, & t \leq 12 \\ 3, & 12 < t < 28 \\ 9, & t \geq 28 \end{cases} \\ C(t) = \frac{\sum_i K_h(t - w_i)y_i}{\sum_i K_h(t - w_i)} \\ E_k(t_k) = C(t_k) \cdot R(t_k) + (1 - C(t_k)) \cdot R(t_k + \Delta) \\ W(\tau, t) = \sum_{k=1}^K n_k \cdot W_k(t_k) \end{array} \right. \quad (12)$$

5.4 模型的求解

针对 BMI 的组间划分以及最佳 NIPT 时点的确定，将其提取为 BMI 分组优化及 NIPT 时点优化问题，采用遗传算法（GA）来优化分组和时点的选择。遗传算法（GA）^[10-12]是一种基于自然选择和遗传机制的优化算法。适用于解决组合优化问题，能够高效处理高位决策空间，得到全局最优结果而非局部最优的问题。

设置遗传算法的 4 个主要参数：

表 4 遗传算法重要参数表

参数	种群规模	迭代代数	交叉概率	变异概率
数值	80	100	0.8	0.2

5.4.1 模型求解结果

利用 python 求解遗传算法得到优化结果如下表所示：

表 5 遗传算法优化结果

最优解 (GA)	第一组	第二组	第三组	第四组	第五组
样本量	217	215	217	216	217
BMI 分组	[20.703,29.960)	[29.960,31.158)	[31.158,32.662)	[32.662,34.442)	[34.442,46.875)
检测周 t_k	9.0	18.3	9.0	9.0	9.0
达标率	0.994	0.859	0.859	0.941	0.967

表 5 根据 BMI 风险等级进行精细化区分，以实现效率和效果的最优平衡，展示了一个高度优化的管理方案。它成功地将人群区分对待，对低风险群体（第一组）和高风险群体（第四、五组）保持标准监测以实现高达标率，实现整体效率的最大化。在检测时点选择中，一三四五组的最佳检测时点均为 9 周（见表 5），属于孕早期，第二组最佳检测时点为 18.3 周，属于孕中期。这与上述风险函数设计一致，即早期发现潜在风险的代价较低，因此 GA 算法优化倾向于选择尽早检测以降低总体期望风险；关于达标率与健康比例，各组在 t_k 的达标率都接近于 1，说明大部分孕妇在该时点男胎的 Y 染色体浓度已达到 4% 的阈值，健康胎儿比例高于 0.859，表明 NIPT 在该时点的总体准确性较高。

5.5 误差影响分析

原本风险定义为：

$$R_i = 1 - \text{达标率}_i \quad (13)$$

加入测量误差后，要对每个孕妇进行多次随机模拟：

$$\hat{R}_i = \frac{1}{N_{\text{sim}}} \sum_{j=1}^{N_{\text{sim}}} \left(1 - \text{达标率} \left(Y_{\text{obs}}^{(j)} \right) \right) \quad (14)$$

其中， $\hat{R}_i$ 是在误差影响下的风险均值， N_{sim} 代表蒙特卡洛模拟次数。可进一步给出误差风险变化区间：




图9 误差风险变化曲线

绘制风险变化曲线直观展示误差对结果的影响。区间越宽，风险对误差越敏感；区间越窄，风险对误差不敏感，结果稳定。误差导致达标率下降，由于检测噪声的存在，一部分本应达标的孕妇会被误判为未达标，从而提高了潜在风险；高BMI人群更敏感，在高BMI组，Y染色体浓度本来就接近阈值，检测误差放大了误判概率，因此风险升高明显；最优检测时点偏后，误差迫使模型延迟检测时点，以提高信号与噪声比，从而保证更高的达标率；稳健性仍较好，虽然误差增加了风险，但分组策略保证了大多数孕妇的风险控制在5%~15%之间。

六、问题三模型的建立与求解

6.1 问题分析

由于男胎Y染色体浓度达标时间受身高、体重、年龄等多种因素影响，文章建立了多因素输出矩阵和检测误差模型，并通过多遗传算法优化孕妇的潜在风险，最终得出合理分组的BMI区间与NIPT检测时点，同时分析了检测误差对结果的影响。




图 10 问题三流程图

6.2 模型的建立

- y_i =第 j 个孕妇的 Y 染色体浓度
- x_j =[孕妇 BMI,身高,体重,年龄,生产次数,检测抽血次数, GC 含量,孕周数值,13 号染色体的 Z 值,18 号染色体的 Z 值,21 号染色体的 Z 值]
- W_j =检测孕周
达标指标:

$$D_j = \begin{cases} 1, & Y_j \geq 0.04 \\ 0, & Y_j < 0.04 \end{cases} \quad (15)$$

6.2.1 BMI 分组

BMI 组间约束边界如下所示:

$$\text{BMI 边界} = [b_1, b_2, b_3, b_4] = [30.279, 31.193, 31.707, 32.563] \quad (16)$$

由此可得 BMI 分组:

$$\begin{cases} g_1 \leq b_1 \\ b_1 < g_2 \leq b_2 \\ b_2 < g_3 < b_3 \\ b_3 < g_4 < b_4 \\ g_5 \geq b_4 \end{cases} \quad (17)$$

6.2.2 达标指示函数

假设检测误差服从真正态分布: $\epsilon_j \sim N(0, \sigma^2)$ 设第 i 组孕妇样本集合为 g_i , 可得到达标指示函数如下所示:

$$S_j = \begin{cases} 1, & y_j + \epsilon_j \geq 0.04 \\ 0, & y_j + \epsilon_j < 0.04 \end{cases} \quad (18)$$

6.3 建立预测模型

选择随机森林多因素预测模型 (RandomForestClassifier) 达标概率进行预测:

$$p_j = P(S_j = 1 | x_j) \quad (19)$$

已知达标概率, 则可计算每组的潜在风险:

$$R_i = 1 - \frac{1}{|g_i|} \sum_{j \in g_i} p_j \quad (20)$$

6.3.1 风险函数

上述得到 BMI 的分组，针对每组设立平均风险，如下所示：

$$R_{avg} = \frac{1}{K} \sum_{i=1}^K R_i (K=3) \quad (21)$$

6.3.2 检测误差

假设检测误差服从真正态分布： $\epsilon_j \sim N(0, \sigma^2)$

检测误差会对达标判断进行干扰，因此将误差纳入达标判断：

$$S_j^{\text{error}} = \begin{cases} 1, & y_j + \epsilon_j \geq 0.04 \\ 0, & \text{否则} \end{cases} \quad (22)$$

设第 i 组的风险预期为 R_i^{error} ，其表达式如下所示：

$$R_i^{\text{error}} = 1 - \frac{1}{|g_i|} \sum_{j \in g_i} E[S_j^{\text{error}}] = 1 - \frac{1}{|g_i|} \sum_{j \in g_i} P(y_j + \epsilon_j \geq 0.04) \quad (23)$$

当 $\sigma=0$ 时， $R_i^{\text{error}}=R_i$ ；当 $\sigma > 0$ 时，随机误差可能导致部分样本达标或未达标，而风险区间 $[R_i^{\min}, R_i^{\max}]$ 则反映了这种波动。

6.3.3 优化目标函数

利用遗传算法优化目标函数，目的为寻求最小平均风险值，即为 $\min_{\{b_1, b_2, b_3\}} R_{avg}^{\text{error}}$ 。其中，优化变量为 BMI 分界点 $\{b_1, b_2\}$ ，考虑误差模拟。

设每组平均孕周为 T_j ，则最佳 NIPT 时点 T_i^{best} ，为其表达式如下所示：

$$T_i^{\text{best}} = \arg \max_t \frac{1}{|g_i|} \sum_{j \in g_i} P(y_j(W_j = t) + \epsilon_j \geq 0.04) \quad (24)$$

6.4 模型的求解

遗传算法优化的目标是最小化平均风险，所求结果为 $R_{avg} = 0.0899$ 。通过 python 计算求解得到结果如下：




图 11 遗传算法收敛曲线

图 11 说明随着代数的增加，虽然曲线前期表现出明显的波动，但最终算法会逐渐找到更优的解，风险值会逐步降低。

表格 6 最优分组

最优解	第一组	第二组	第三组	第四组	第五组
样本量	276	160	91	113	442
BMI 分组	[20.703,30.279)	[30.279,31.193)	[31.193,31.707)	[31.707,32.563)	[32.563,46.875)
风险均值	0.1305	0.0964	0.0765	0.1481	0.1691
风险标准差	0.0079	0.0103	0.0161	0.0157	0.0070
最佳孕周	19.10	21.20	13.30	12.60	18.94
达标率	0.124	0.131	0.140	0.142	0.079

上述结果显示，经过遗传算法（GA），得到男胎孕妇 BMI 的最优分组阈值。其中，第一组的风险均值（0.1305）处于较高水平，风险标准差（0.0079）较小，表明第一组内的个体风险比较集中稳定；第二组风险均值（0.0964）在所有组中第二低，且风险标准差（0.0103）适中，表明此区间孕妇的整体风险控制在一个较好的水平；第三组，风险均值（0.0765）为**全队列最低**，是风险表现最优异的区间；第四组的风险均值（0.1481），风险标准差（0.0157）为**高风险群体**，表明组内风险异质性高；第五组的风险均值（0.1691）为**全组列最高值**，且风险标准差（0.0070）最小，表明该组孕妇普遍处于高位且稳定的风险水平。综合来看，本次遗传算法优化揭示了不同 BMI 区间的不同特性，在临床上建议针对高风险孕妇进行重点监控并持续优化检测方案。

6.5 误差分析




图 12 误差结果分析

在所示柱状图中，每组柱体代表该组的风险均值，柱体上方有误差条（即标准差），并在柱体内部标注了每组的最佳孕周数。从数据上看，第一组的风险均值最低（0.125），而第五组的风险均值最高（0.175）。这表明不同组之间的风险水平差异较大，但是风险均值的波动范围并不明显，且标准差的变化趋势可能暗示部分组别在孕周上的变动较为敏感，特别是第二组和第三组的标准差值较大，

这意味这些组的风险值较为不稳定。

七、问题四模型的建立与求解

7.1 问题分析

根据题目附件说明，由 AB 列检测出 13 号、18 号、21 号染色体存在非整倍体数量异常，空白则表示无异常。基于此，可将染色体数量异常值编码为患病(1)，非异常值编码为未患病 (0)。由于该问题属于患病与未患病的二分类模型问题，本文以是否患病为因变量，以 X 染色体及 13 号、18 号、21 号染色体的 Z 值、GC 含量、读段数及相关比例，以及 BMI 等因素为自变量，建立 Logistic Regression 女胎异常模型，并对模型进行敏感性分析。




图 13 问题四流程图

7.2 模型的建立

和问题一做相同的数据预处理，构建逻辑回归模型^[13-15]，通过预测异常概率及阈值判定胎儿是否异常。逻辑回归数学模型如下所示：

$$P(Y = 1 | X) = \frac{1}{1 + e^{-(b_0 + b_1X_1 + b_2X_2 + \dots + b_nX_n)}} \tag{25}$$

其中， $P(Y = 1)$ 是女胎异常的概率， b_0 为截距， $b_1, b_2, \dots, b_n$ 为各个自变量的回归系数， $X_1, X_2, \dots, X_n$ 为自变量，即年龄、身高、体重等。通过计算各个自变量的回归系数 $b_1, b_2, \dots, b_n$ ，表示每个自变量对女胎异常这个事件发生概率的影响。

7.3 模型的求解

经计算，各个自变量的回归系数如下表（见表 7）所示：

表 7 各自变量回归系数

特征	回归系数	特征	回归系数
年龄	-0.5115	13 号染色体的 Z 值	0.0121
身高	-0.0395	18 号染色体的 Z 值	0.0850
体重	-0.2228	21 号染色体的 Z 值	0.4359
IVF 妊娠	-0.1020	X 染色体的 Z 值	-0.3121

检测抽血次数	-0.1641	X 染色体浓度	-1.1071
检测孕周	0.4846	13 号染色体的 GC 含量	0.9368
孕妇 BMI	-0.1412	18 号染色体的 GC 含量	0.5391
原始读段数	-0.1078	21 号染色体的 GC 含量	-1.2075
参考基因组上比对的比例	0.2307	被过滤掉读段数的比例	0.4248
重复读段的比例	-0.0827	怀孕次数	-0.1105
唯一比对的读段数	-0.0457	生产次数	-0.2474
GC 含量	-0.0674		

在逻辑回归中，回归系数表示“自变量每增加一个单位时，目标事件发生概率的对数几率（Log-Odds）”的变化量。若为正值，当该自变量增加时，目标事件发生的对数几率增加，即发生概率增加；反之则发生对数几率减少，即发生概率减少。回归系数绝对值的大小决定该自变量的影响强度，绝对值越大，则影响强度越大。

7.4 结果分析




图 14 逻辑回归特征重要性曲线曲线

13 号染色体的 GC 含量(0.937)为影响强度最大的(见表 7)正向影响因子,其余几项如检测孕周、21 号染色体的 Z 值、18 号染色体的 GC 含量、被过滤掉读段数的比例等自变量则具有较强的正向关联;另外,21 号染色体的 GC 含量(-1.2075)为影响强度最大的负向影响因子,此外年龄(-0.511)该项自变量在该预测目标上降低的目标事件发生的预测概率,即表示孕妇的年龄增长反而降低胎儿染色体产生异常风险的概率。其余自变量回归系数的绝对值相对较小,对目标事件即女胎异常的影响强度(见图 11)较小。

7.4 模型的评估

多因素 Logistic 回归模型的各项性能评估参数如下表(表 8)所示:

表 8 各项性能评估参数表

模型性能评估	参数
AUC 值	0.8395
灵敏度	0.2500
特异性	1.0000
假阳性率	0.0000
假阴性率	0.7500

该模型的 AUC 值为 0.8395, 具备优良判断水准;灵敏度较低,可能遗漏真实患者情况;特异性为 1.00, 对应的假阳性率为 0, 这表明该模型识别阴性样本的识别率极高,能有效确保预测阴性样本对于目标事件发生概率的准确性。该模型的 AUC—ROC 曲线如下图所示:




图 15 ROC 曲线

图 15 用于区分阳性样本(患病/异常)和阴性样本(正常)的整体能力。其中 ROC 曲线的横轴是假阳性率 (FPR),纵轴是真阳性率 (TPR)。如上图所示,模型区分正负类的能力较强,始终优于随机猜测,能优先捕捉高置信度正例。

为直观显示该模型在特定分类阈值下的预测结果与实际标签的对比,绘制 2x2 混淆矩阵热力图(Confusion Matrix Heatmap)进行展示,如下图所示:




图 16 混淆矩阵

由图 16 可知，在真实结果为 0 的类别中，预测结果为 0 的有 154 个，预测结果为 1 的是 0 个，这意味着对于真实为 0 的样本，模型全部预测正确，没有出现误判的情况。对于真实结果为 1 的类别，预测结果为 0 的有 21 个，预测结果为 1 的有 7 个，模型整体分类正确率较高。预测为 1 的样本全部正确，但代价是漏诊 21 例（FN）。精确率和召回率不平衡，F1 分数较低。虽然存在一定数量的预测错误，但整体上，模型在主要类别（真实结果为 0）上的预测准确率达到 100%，展现出很强的识别能力，综合来看，这个模型的性能较出色。

八、模型的评价与推广

8.1 模型的优点

（1）预测结果准确稳定性强：相较传统最小二乘法（OLS），采用稳健回归降低原始数据异常值干扰，提升模型在噪声数据中的表现，避免因数据极端值导致的参数偏移，提升 Y 染色体浓度预测的稳定性。

（2）决策处理优化效率高：利用遗传算法（GA）解决多变量非线性约束问题，能够高效处理高位决策空间，避免局部最优的问题，快速收敛至全局最优解。

（3）模型抗干扰能力强：通过蒙特卡洛模拟引入正态噪声，量化检测误差对风险预测的实际影响，通过分组策略有效针对误差风险变化引起的风险概率误判的问题。

8.2 模型的缺点

（1）数据计算复杂度较高：采用遗传算法（GA）确立 80 种种群规模迭代 100 次，蒙特卡洛模拟需对加入测量误差后的每个孕妇进行多次随机模拟，计算复杂程度较高，耗时较长。

8.3 模型的推广

本文模型针对不同性别胎儿的异常检测以及孕妇最佳孕期的判断，通过对不同孕妇 BMI 的合理分组，提取多因素判断，以及将检测误差纳入风险预测等处理手段，科学有效地进行生育指导规划以及风险防控。

参考文献

- [1] Gadsbøll K, Vogel I, Kristensen S E, et al. Combined first-trimester screening and invasive diagnostics for atypical chromosomal aberrations: Danish nationwide study of prenatal profiles and detection compared with NIPT[J]. *Ultrasound in Obstetrics & Gynecology*, 2024, 64(4): 470-479.
- [2] 张鹏,莫伟英,蒙明慧,等. 无创产前检测对性染色体非整倍体检出情况的影响及相关伦理思考[J].*中国临床新医学*,2025,18(06):690-695.
- [3] Bayindir B, Dehaspe L, Brison N, et al. Noninvasive prenatal testing using a novel analysis pipeline to screen for all autosomal fetal aneuploidies improves pregnancy management[J]. *European Journal of Human Genetics*, 2015, 23(10): 1286-1293.
- [4] 徐衡,姜新年,李静,等. 重度新生儿高胆红素血症并发急性胆红素脑病影响因素及 MRI 影像特征分析[J].*临床放射学杂志*,2025,44(09):1744-1749.
- [5] Coronel-Brizio H F, Hernández-Montoya A R, Rodríguez-Achach M E, et al. Anderson-Darling and Watson tests for the geometric distribution with estimated probability of success[J]. *PloS one*, 2024, 19(12): e0315855.
- [6] Ejegwa P A, Kausar N, Aydin N, et al. A novel Pythagorean fuzzy correlation coefficient based on Spearman's technique of correlation coefficient with applications in supplier selection process[J]. *Journal of Industrial Information Integration*, 2025, 44: 100762.
- [7] 居仁婷,黄海燕,杨红霞. 妊娠期糖尿病孕妇孕期BMI变化及糖化白蛋白与大于胎龄儿的相关性研究 [J]. *大医生*, 2025, 10 (13): 92-94.
- [8] 潘瑞平,杨华,信博翔,等. 基于斯皮尔曼相关系数的台区停电风险监测预警方法 [J]. *中国新技术新产品*, 2025, (05): 137-139. DOI:10.13612/j.cnki.cntp.2025.05.026.
- [9] 宋腾蛟,刘英,王琰,等. 基于多元线性回归的黏性土物理力学参数相关性——以长春市中心城区为例[J].*吉林大学学报(地球科学版)*,2025,55(04):1225-1239.
- [10] 韩杰,王然风,付翔,等. 基于遗传算法优化的 LightGBM 浮选尾煤灰分预测模型研究[J].*矿业研究与开发*,2025,45(01):269-276.
- [11] Králev V, Králeva R. Combining genetic algorithm with local search method in solving optimization problems[J]. *Electronics*, 2024, 13(20): 4126.
- [12] 郝昕宇,廖希,王洋,等. 基于 mRMR-GA 的太赫兹信道场景识别研究[J].*通信学报*,2025,46(05):91-102.
- [13] 徐锐,张岱,韩鹏,等. 基于决策树与 Logistic 回归模型预测实性肺腺癌结节脏层胸膜侵犯[J].*临床放射学杂志*,2025,44(09):1642-1649.
- [14] Yan M, Tao R, Li S, et al. Clinical characteristics and logistic regression analysis of macrolide-resistant *Mycoplasma pneumoniae* pneumonia in children[J]. *European Journal of Clinical Microbiology & Infectious Diseases*, 2024, 43(9): 1825-1835.
- [15] Jin S, Zhai C, Liu J, et al. Seismic fragility analysis of nuclear containment structure using Bayesian logistic regression model[J]. *Soil Dynamics and Earthquake Engineering*, 2024, 178: 108435.
- [16] Chatgpt,Chatgpt-5,OpenAI, (Chatgpt) , 2025-09-07

附录:

所有变量直方图总览




图 17 多因子直方图




图 18 矩阵散点图

Python 热力图绘制 problem1

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from matplotlib.colors import LinearSegmentedColormap

# 解决中文显示问题
plt.rcParams['font.sans-serif'] = ['SimHei']
plt.rcParams['axes.unicode_minus'] = False

# ===== 构造 DataFrame =====
df = pd.read_excel("数据/附件.xlsx", sheet_name="热力图")

# Spearman 相关系数计算
xiangguanxishu = df.corr(method='spearman')

# 保存相关系数矩阵
xiangguanxishu.to_excel("Spearman 相关系数矩阵.xlsx")
```

```

# ===== 自定义浅红配色 =====
colors = ["#175491", "white", "#e34d20"] # 蓝 → 白 → 浅红
#可自行挑选颜色
custom_cmap =
LinearSegmentedColormap.from_list("blue_white_lightred", colors)

# ===== 绘制热力图 =====
plt.figure(figsize=(12, 10))
sns.heatmap(
xiangguanxishu,
annot=True,
cmap=custom_cmap, # 使用自定义配色
center=0,
fmt=".2f",
cbar_kws={"shrink": 0.8, "label": "Spearman 相关系数"}
)
plt.title("Spearman 相关系数热力图", fontsize=16, weight="bold")
plt.xticks(rotation=45, ha="right")
plt.yticks(rotation=0)
plt.tight_layout()
plt.savefig("图片/Spearman 相关系数热力图.png", dpi=600,
bbox_inches="tight")
plt.show()

```

Python 箱线图与直方图 problem1

```

import pandas as pd
import numpy as np
from scipy import stats
import seaborn as sns
from scipy.stats import anderson
import matplotlib.pyplot as plt
import statsmodels.api as sm
import os
from openpyxl import Workbook
from openpyxl.styles import Font, PatternFill, Alignment

# 设置中文字体
plt.rcParams['font.sans-serif'] = ['SimHei']
plt.rcParams['axes.unicode_minus'] = False

# 创建保存图片的目录
tupiandir = "正态性检验图片"
os.makedirs(tupiandir, exist_ok=True)

```

```

# 读取数据
df = pd.read_excel("数据/附件.xlsx", sheet_name="热力图")

# 定义要检验的所有变量
variables_to_test = [
    '年龄', '身高', '体重', '检测抽血次数', '检测孕周', '孕妇 BMI',
    '原始读段数', '在参考基因组上比对的比例', '重复读段的比例', '唯一比对的读段数',
    'GC 含量', '13 号染色体的 Z 值', '18 号染色体的 Z 值', '21 号染色体的 Z 值',
    'X 染色体的 Z 值', 'Y 染色体的 Z 值', 'Y 染色体浓度', 'X 染色体浓度',
    '13 号染色体的 GC 含量', '18 号染色体的 GC 含量', '21 号染色体的 GC 含量',
    '被过滤掉读段数的比例', '生产次数'
]

# Anderson-Darling 检验函数
def ad_test(data, name):
    """执行Anderson-Darling 正态性检验并返回结果字典"""
    data_clean = data.dropna()
    if len(data_clean) < 8:
        return {"变量": name, "错误": "样本量不足(<8)"}

    try:
        result = anderson(data_clean, dist='norm')
        res = {
            "变量": name,
            "样本量": len(data_clean),
            "Anderson 统计量": round(result.statistic, 4),
            "偏度": round(stats.skew(data_clean), 4),
            "峰度": round(stats.kurtosis(data_clean), 4),
            "均值": round(np.mean(data_clean), 4),
            "标准差": round(np.std(data_clean, ddof=1), 4)
        }
    # 添加不同显著性水平的临界值和结论
    sig_levels = [15, 10, 5, 2.5, 1]
    for i, sl in enumerate(sig_levels):
        if i < len(result.critical_values):
            cv = result.critical_values[i]
            res[f"{sl}%临界值"] = round(cv, 4)
            res[f"{sl}%水平结论"] = "不服从正态分布" if result.statistic > cv else "接近正态分布"
    # 以 5%水平作为主要结论
    res["正态性结论(5%)"] = "不服从正态分布" if result.statistic > result.critical_values[2] else "接近正态分布"
    return res

```


[illegible]

```

# 调整列宽
for col in ws.columns:
    max_length = max(len(str(cell.value)) for cell in col)
    ws.column_dimensions[col[0].column_letter].width = min(max_length +
2, 50)

wb.save(output_path)

styled_output = "数据/美化版正态性检验结果.xlsx"
create_styled_excel_report(final_df, styled_output)
print(f"已保存美化版报告到 {styled_output}")

# 可视化
print("正在生成可视化图表...")
normality_summary = final_df['正态性结论(5%)'].value_counts()
plt.figure(figsize=(8, 6))
normality_summary.plot(kind='bar', color=['#4CAF50', '#F44336'])
# 选取喜欢的配色
plt.title('变量正态性分布情况汇总')
plt.xlabel('检验结论')
plt.ylabel('变量数量')
plt.xticks(rotation=0)
plt.tight_layout()
plt.savefig(os.path.join(tuplindir, "正态性检验汇总.png"), dpi=300,
bbox_inches='tight')
plt.close()

# 为每个变量生成QQ图和直方图
for var in variables_to_test:
    if var in df.columns:
        data = df[var].dropna()
        if len(data) > 3:
            fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(12, 5))
            fig.suptitle(f'{var} 分布检验', fontsize=16)
            sm.qqplot(data, line='s', ax=ax1, marker='o', color="#ADDF1A",
alpha=0.7)
            ax1.get_lines()[1].set_linestyle('--') # 把参考线改为虚线
            ax1.set_title(f'{var} QQ图')
            ax2.hist(data, bins=30, density=True, alpha=0.6, color='g')
            ax2.set_title(f'{var} 直方图')
            ax2.set_xlabel('值')
            ax2.set_ylabel('密度')
            xmin, xmax = ax2.get_xlim()

```

```

x = np.linspace(xmin, xmax, 100)
p = stats.norm.pdf(x, np.mean(data), np.std(data))
ax2.plot(x, p, 'k', linewidth=1.5)
textstr = f'n={len(data)}\n 均值={np.mean(data):.2f}\n 标准差\n={np.std(data):.2f}'
props = dict(boxstyle='round', facecolor='wheat', alpha=0.5)
ax2.text(0.05, 0.95, textstr, transform=ax2.transAxes, fontsize=10,
verticalalignment='top', bbox=props)
plt.tight_layout()
img_path = os.path.join(tupiandir, f"{var}_分布检验.png")
plt.savefig(img_path, dpi=300, bbox_inches='tight')
plt.close()

# ===== 添加一个总图 =====
print("正在生成直方图总览...")

# 筛选实际存在的变量
valid_vars = [var for var in variables_to_test if var in df.columns]
num_vars = len(valid_vars)
colors = sns.color_palette("tab10", num_vars)
# "Set2" 也可以换成 "Paired", "tab10", "pastel"
# 设置子图行列数 (比如每行 4 个)
cols = 4
rows = (num_vars + cols - 1) // cols

fig, axes = plt.subplots(rows, cols, figsize=(4*cols, 3*rows))
axes = axes.flatten()

for i, var in enumerate(valid_vars):
    data = df[var].dropna()
    if len(data) > 3:
        axes[i].hist(data, bins=30, density=True, alpha=0.6, color=colors[i])
        xmin, xmax = axes[i].get_xlim()
        x = np.linspace(xmin, xmax, 100)
        p = stats.norm.pdf(x, np.mean(data), np.std(data))
        axes[i].plot(x, p, 'k', linewidth=1.2)
        axes[i].set_title(var, fontsize=10)
    else:
        axes[i].set_title(f"{var} (数据不足)", fontsize=10)
        axes[i].axis('off')

# 删除空白子图
for j in range(i+1, len(axes)):

```

```

axes[j].axis('off')

plt.suptitle("所有变量直方图总览", fontsize=16)
plt.tight_layout(rect=[0, 0, 1, 0.96])
summary_img_path = os.path.join(tupiandir, "直方图总览.png")
plt.savefig(summary_img_path, dpi=300, bbox_inches='tight')
plt.close()

print(f"直方图总览已保存到 {summary_img_path}")
print("所有图表已保存完毕! ")

# 输出简要总结
norm_count = sum(final_df['正态性结论(5%)'] == '接近正态分布')
non_norm_count = sum(final_df['正态性结论(5%)'] == '不服从正态分布')
print(f"\n=== 正态性检验总结 ===")
print(f"总共检验变量: {len(final_df)}个")
print(f"接近正态分布的变量: {norm_count}个")
print(f"不服从正态分布的变量: {non_norm_count}个")
print(f"详细结果已保存到: {output_path}")
print(f"可视化图表保存在: {tupiandir} 目录")

```

Python 孕周转化为浮点数 数据预处理

```

import pandas as pd
import re

df = pd.read_excel("数据/附件.xlsx", sheet_name="problem1")
# df = pd.read_excel("数据/problem4.xlsx")

def convert_week(week_str):
    """
    将孕周 '11w+6' 或 '14w' 转换为浮点周数,
    并自动修正天数大于6 的情况
    """
    if pd.isna(week_str):
        return None

    s = str(week_str).strip().lower()

    # 匹配格式: 数字w(+数字)
    match = re.match(r"(\d+)w(?:\+(\d+))?", s)
    if match:
        week = int(match.group(1))
        day = int(match.group(2)) if match.group(2) else 0

        # 修正: 如果天数 >= 7, 进1周
        if day >= 7:

```

```

        week += day // 7
        day = day % 7

    return week + day / 7
else:
    return None

# 示例数据

df["孕周 float"] = df["检测孕周"].apply(convert_week)
output_file = "数据/孕周转换结果.xlsx"
df.to_excel(output_file, index=False)
print(f"已保存到 {output_file}")

```

Python problem2

```

# ga_opt_nipt_improved_with_error.py
import random
import numpy as np
import os
import pandas as pd
from deap import base, creator, tools, algorithms
import matplotlib.pyplot as plt
import multiprocessing
import warnings

plt.rcParams['font.sans-serif'] = ['SimHei']
plt.rcParams['axes.unicode_minus'] = False
warnings.filterwarnings("ignore")

# ----- 配置 -----
DATA_PATH = "数据/附件.xlsx"
BMI_COL = "孕妇 BMI"
Y_COL = "Y 染色体浓度"
WEEK_COL = "检测孕周"
ID_COL = "孕妇代码"

K = 5 # 分组数可以根据需求更改
T_MIN, T_MAX = 9.0, 26.0
DELTA = 2.0
PI_MIN = 0.2 # 各个ga 算法的参数
PENALTY_FACTOR = 1e3
SIGMA_Y = 0.01 # Y 染色体浓度测量误差

POP_SIZE = 80

```

```

NGEN = 100
CXPB = 0.8
MUTPB = 0.2
SEED = 42

random.seed(SEED)
np.random.seed(SEED)

# ----- 辅助函数 -----
def cost_func(t):
    """分段代价"""
    if t <= 12:
        return 1.0
    elif t < 28:
        return 3.0
    else:
        return 9.0

# ----- 读取数据 -----
df = pd.read_excel(DATA_PATH, sheet_name="problem2")
df = df[[ID_COL, BMI_COL, Y_COL, WEEK_COL, "胎儿是否健康"]].dropna()
df["达标"] = df["胎儿是否健康"].apply(lambda x: 1 if x == "是" else 0)
df = df[(df[BMI_COL] > 10) & (df[BMI_COL] < 60)].copy()
n = len(df)
print(f"读取记录数: {n}")

bmis = df[BMI_COL].values

# ----- 核平滑函数 -----
GRID_STEP = 0.1
t_grid = np.arange(T_MIN, T_MAX + GRID_STEP, GRID_STEP)

def build_group_pfunc(group_df, sigma=0):
    """计算核平滑概率函数, 支持模拟误差"""
    if len(group_df) == 0:
        return np.zeros_like(t_grid)
    times = group_df[WEEK_COL].values
    y_vals = group_df[Y_COL].values
    if sigma > 0:
        y_vals = y_vals + np.random.normal(0, sigma, size=len(y_vals))
    hits = (y_vals >= 0.04).astype(int)
    bw = 0.7
    pvals = []
    for tg in t_grid:

```



```

        weights = np.exp(-0.5 * ((times - tg) / bw)**2)
        pvals.append(np.sum(weights * hits) / np.sum(weights) if
weights.sum() > 0 else 0.0)
    return np.array(pvals)

# ----- GA 编码 -----
creator.create("FitnessMin", base.Fitness, weights=(-1.0,))
creator.create("Individual", list, fitness=creator.FitnessMin)
BMI_MIN, BMI_MAX = df[BMI_COL].min(), df[BMI_COL].max()
toolbox = base.Toolbox()

def init_individual():
    taus = [random.uniform(BMI_MIN, BMI_MAX) for _ in range(K-1)]
    ts = [random.uniform(T_MIN, T_MAX) for _ in range(K)]
    return taus + ts

toolbox.register("individual", tools.initIterate, creator.Individual,
init_individual)
toolbox.register("population", tools.initRepeat, list,
toolbox.individual)
toolbox.register("mate", tools.cxBlend, alpha=0.5)
toolbox.register("mutate", tools.mutGaussian, mu=0, sigma=1.0,
indpb=0.2)
toolbox.register("select", tools.selTournament, tournsize=3)

def repair(ind):
    ind = [float(x) for x in ind]
    taus = sorted([min(max(x, BMI_MIN), BMI_MAX) for x in ind[:K-1]])
if K > 1 else []
    ts = [min(max(x, T_MIN), T_MAX) for x in ind[K-1:]]
    return taus + ts

# ----- 适应度函数 -----
def evaluate(individual):
    individual = repair(individual)
    taus = sorted(individual[:K-1]) if K > 1 else []
    ts = individual[K-1:]
    boundaries = [-1e9] + taus + [1e9]
    group_indices = [[] for _ in range(K)]
    for idx, bmi in enumerate(bmis):
        for k in range(K):
            if boundaries[k] < bmi <= boundaries[k+1]:
                group_indices[k].append(idx)
            break

```

```

total_risk = 0.0
penalty = 0.0
for k in range(K):
    indices = group_indices[k]
    if len(indices) < max(3, PI_MIN * n):
        penalty += PENALTY_FACTOR * (1.0 + max(0, (PI_MIN * n) -
len(indices)))
    group_df = df.iloc[indices]
    pgrid = build_group_pfunc(group_df, sigma=SIGMA_Y)
    t_k = ts[k]
    i = min(max(int((t_k - T_MIN) / GRID_STEP), 0), len(pgrid)-2)
    frac = (t_k - (T_MIN + i*GRID_STEP)) / GRID_STEP
    p_t = pgrid[i]*(1-frac) + pgrid[i+1]*frac
    c_t = cost_func(t_k)
    c_td = cost_func(t_k + DELTA)
    total_risk += len(indices) * (p_t*c_t + (1-p_t)*c_td)
    if p_t < 0.05:
        penalty += PENALTY_FACTOR * (0.05 - p_t)
return (total_risk + penalty,)

toolbox.register("evaluate", evaluate)

# ----- GA 运行 -----
def run_ga():
    pop = toolbox.population(n=POP_SIZE)
    hof = tools.HallOfFame(5)
    stats = tools.Statistics(lambda ind: ind.fitness.values)
    stats.register("min", np.min)
    stats.register("avg", np.mean)
    pop, log = algorithms.eaSimple(pop, toolbox, cxpb=CXPB,
mutpb=MUTPB,
                                ngen=NGEN, stats=stats,
halloffame=hof, verbose=True)
    return pop, log, hof

# ----- 主函数 -----
def main():
    pool = multiprocessing.Pool()
    toolbox.register("map", pool.map)
    pop, log, hof = run_ga()
    pool.close()
    pool.join()

```

```

# ----- 最优解 -----
best = repair(list(hof[0]))
taus = sorted(best[:K-1]) if K > 1 else []
ts = best[K-1:]
print("\n===== 最优解 (GA) =====")
print("BMI 阈值划分点:", taus)
print("每组检测周 t_k:", ts)
print("fitness:", hof[0].fitness.values)

# ----- 每组统计 -----
boundaries = [-1e9] + taus + [1e9]
group_stats = []
for k in range(K):
    mask_idx = [i for i, bmi in enumerate(bmis) if boundaries[k] <
bmi <= boundaries[k+1]]
    sub = df.iloc[mask_idx]
    t_k = ts[k]
    pgrid = build_group_pfunc(sub, sigma=SIGMA_Y)
    i = min(max(int((t_k - T_MIN) / GRID_STEP), 0), len(pgrid)-2)
    frac = (t_k - (T_MIN + i*GRID_STEP)) / GRID_STEP
    p_t = pgrid[i]*(1-frac) + pgrid[i+1]*frac
    healthy_ratio = (sub["胎儿是否健康"] == "是").sum() / max(1,
len(sub))
    group_stats.append((k+1, len(mask_idx), float(round(p_t,3)),
float(round(t_k,2)), float(round(healthy_ratio,3))))

print("\n 每组统计 (组序, 样本数, 达标率@t, t, 健康比例):")
for stat in group_stats:
    print(stat)

# ----- 保存结果 -----
results_path = os.path.join("数据", "GA_results_with_error.xlsx")
with pd.ExcelWriter(results_path) as writer:
    best_df = pd.DataFrame({"BMI 阈值划分点":
pd.Series(taus).reindex(range(K)),
                           "检测周 t_k":
pd.Series(ts).reindex(range(K))})
    best_df.to_excel(writer, sheet_name="最优解", index=False)
    group_df = pd.DataFrame(group_stats, columns=["组序", "样本数", "
达标率@t", "检测周 t", "健康比例"])
    group_df.to_excel(writer, sheet_name="分组统计", index=False)
    print(f"\n 结果已保存到 {os.path.abspath(results_path)}")

# ----- 绘图 -----

```

```

plt.figure(figsize=(8,5))
for k in range(K):
    mask_idx = [i for i, bmi in enumerate(bmis) if boundaries[k] <
bmi <= boundaries[k+1]]
    sub = df.iloc[mask_idx]
    pgrid = build_group_pfunc(sub, sigma=SIGMA_Y)
    risk_grid = pgrid*np.vectorize(cost_func)(t_grid) + (1-
pgrid)*np.vectorize(cost_func)(t_grid+DELTA)
    plt.plot(t_grid, risk_grid, label=f"组{k+1}
(n={len(mask_idx)}, 健康比例={group_stats[k][4]:.2f})")
    plt.scatter([ts[k]], [risk_grid[min(int((ts[k]-
T_MIN)/GRID_STEP), len(risk_grid)-1)]]], marker='x', s=60)
    plt.xlabel("孕周 (周)")
    plt.ylabel("期望风险")
    plt.title("每组风险曲线与 GA 选定的时点 (含检测误差)")
    plt.legend()
    plt.grid(True)
    plt.tight_layout()
    plt.savefig("图片/risk_plot_with_error.png", dpi=150)
    print("\n 风险曲线已保存为 图片/risk_plot_with_error.png")
    plt.show()

if __name__ == "__main__":
    multiprocessing.freeze_support()
    main()
    # ===== 不同误差  $\sigma$  下的风险曲线 =====
def risk_with_error(df, sigma):
    """ 计算在指定检测误差 sigma 下的平均风险 """
    if df.empty:
        return 1.0
    probs = []
    for _ in range(30): # 重复模拟, 平滑曲线
        y_sim = df[Y_COL] + np.random.normal(0, sigma, size=len(df))
        y_sim = (y_sim >= 0.04).astype(int) # 达标与否
        probs.append(1 - np.mean(y_sim)) # 风险 = 1 - 达标率
    return np.mean(probs)

sigmas = [0.001, 0.002, 0.005, 0.01, 0.02] # 不同检测误差水平
risks = [risk_with_error(df, s) for s in sigmas]

# 保存结果
df_sigma = pd.DataFrame({"sigma": sigmas, "风险": risks})
df_sigma.to_excel("数据/风险_vs_sigma.xlsx", index=False)

```

```

# 绘制并保存
plt.figure(figsize=(8,6))
plt.plot(sigmas, risks, marker='o', linewidth=2)
plt.xlabel("检测误差  $\sigma$ ")
plt.ylabel("平均风险  $R(\sigma)$ ")
plt.title("不同检测误差  $\sigma$  下的风险变化曲线")
plt.grid(True, linestyle="--", alpha=0.6)
plt.savefig("图片/risk_vs_sigma.png", dpi=300, bbox_inches="tight")
plt.close()
print("不同  $\sigma$  下风险曲线已保存为 图片/risk_vs_sigma.png")

```

Python problem3

```

import pandas as pd
import numpy as np
from deap import base, creator, tools, algorithms
from sklearn.ensemble import RandomForestClassifier
import random
import matplotlib.pyplot as plt
import matplotlib.cm as cm
plt.rcParams['font.sans-serif'] = ['SimHei']
plt.rcParams['axes.unicode_minus'] = False

# ----- 配置 -----
MIN_GROUP_SIZE = 50
Y_COL = "Y 染色体浓度"
WEEK_COL = "检测孕周"
NUM_GROUPS = 5
NUM_BOUNDS = NUM_GROUPS - 1
ERROR_STD = 0.005 #  $\sigma$ , 可根据实际检测误差调整

# ----- 数据加载 -----
df = pd.read_excel("数据/附件.xlsx", sheet_name="problem3")
df_male = df[df[Y_COL].notnull()].copy()

# ----- 孕周转换 -----
def parse_week(week_str):
    if isinstance(week_str, str) and "w+" in week_str:
        try:
            w, d = week_str.split("w+")
            return int(w) + int(d) / 7
        except:
            return np.nan
    elif isinstance(week_str, (int, float)):

```

```

        return week_str
    return np.nan

df_male['孕周数值'] = df_male[WEEK_COL].apply(parse_week)

# ----- 构造目标变量 -----
df_male["达标"] = (df_male[Y_COL] >= 0.04).astype(int)

# ----- 多因素预测模型 -----
features = [
    '孕妇 BMI', '身高', '体重', '年龄', '生产次数',
    '检测抽血次数', 'GC 含量', '孕周数值',
    '13 号染色体的 Z 值', '18 号染色体的 Z 值', '21 号染色体的 Z 值'
]

X = df_male[features]
y = df_male['达标'].astype(int)

clf = RandomForestClassifier(n_estimators=100, random_state=42)
clf.fit(X, y)

# ----- 考虑检测误差的达标概率 -----
def predict_prob_with_error_simulation(df_group, n_sim=50):
    if df_group.empty:
        return 0, 0
    probs_sim = []
    for _ in range(n_sim):
        y_error = df_group[Y_COL].values + np.random.normal(0,
ERROR_STD, len(df_group))
        probs_sim.append(np.mean(y_error >= 0.04))
    risk_mean = 1 - np.mean(probs_sim)
    risk_std = np.std(probs_sim)
    return risk_mean, risk_std

# ----- 计算某组的最佳孕周 -----
def best_week_for_group(group):
    if group.empty:
        return None, None
    week_range = np.arange(group['孕周数值'].min(), group['孕周数值']
'].max()+0.1, 0.1)
    best_week, best_prob = None, -1
    for w in week_range:
        sub = group[np.abs(group['孕周数值'] - w) < 0.25]
        if len(sub) < 5:

```

```

        continue
    _, prob_mean = predict_prob_with_error_simulation(sub)
    if prob_mean > best_prob:
        best_prob, best_week = prob_mean, w
    return best_week, best_prob

# ----- GA 配置 -----
BMI_min, BMI_max = df_male['孕妇 BMI'].min(), df_male['孕妇 BMI'].max()

creator.create("FitnessMin", base.Fitness, weights=(-1.0,))
creator.create("Individual", list, fitness=creator.FitnessMin)

toolbox = base.Toolbox()
toolbox.register("attr_float", random.uniform, BMI_min, BMI_max)
toolbox.register("individual", tools.initRepeat, creator.Individual,
                  toolbox.attr_float, n=NUM_BOUNDS)
toolbox.register("population", tools.initRepeat, list,
                  toolbox.individual)

# ----- 风险函数 -----
def eval_risk_with_error(individual):
    bounds = sorted(individual)
    risks = []
    valid = True
    for i in range(NUM_GROUPS):
        if i == 0:
            group = df_male[df_male['孕妇 BMI'] <= bounds[0]]
        elif i == NUM_GROUPS - 1:
            group = df_male[df_male['孕妇 BMI'] > bounds[-1]]
        else:
            group = df_male[(df_male['孕妇 BMI'] > bounds[i - 1]) &
                             (df_male['孕妇 BMI'] <= bounds[i])]
        if len(group) < MIN_GROUP_SIZE:
            valid = False
            break
        risk_mean, _ = predict_prob_with_error_simulation(group)
        risks.append(risk_mean)
    if not valid or not risks:
        return (1.0,)
    return (np.mean(risks),)

toolbox.register("evaluate", eval_risk_with_error)
toolbox.register("mate", tools.cxBlend, alpha=0.5)

```



```

toolbox.register("mutate", tools.mutGaussian, mu=0, sigma=2,
indpb=0.2)
toolbox.register("select", tools.selTournament, tournsize=3)

# ----- GA 运行 -----
def main():
    pop = toolbox.population(n=50)
    ngen = 40
    cxpb, mutpb = 0.5, 0.2

    logbook = tools.Logbook()
    logbook.header = ["gen", "min", "avg"]

    for gen in range(ngen):
        offspring = algorithms.varAnd(pop, toolbox, cxpb, mutpb)
        fits = list(map(toolbox.evaluate, offspring))
        for fit, ind in zip(fits, offspring):
            ind.fitness.values = fit
        pop = toolbox.select(offspring, len(pop))

        fits = [ind.fitness.values[0] for ind in pop]
        record = {"gen": gen, "min": np.min(fits), "avg":
np.mean(fits)}
        logbook.record(**record)
        print(logbook.stream)

    best_ind = tools.selBest(pop, 1)[0]
    best_bounds = sorted(best_ind)

    print("\n===== 最优结果 =====")
    print("BMI 分界点:", best_bounds)
    print("最小风险:", eval_risk_with_error(best_ind)[0])

    group_risk_means = []
    group_risk_stds = []
    best_weeks = []

    # 每组统计 + 最佳孕周 + 风险均值/标准差
    for i in range(NUM_GROUPS):
        if i == 0:
            group = df_male[df_male['孕妇 BMI'] <= best_bounds[0]]
        elif i == NUM_GROUPS - 1:
            group = df_male[df_male['孕妇 BMI'] > best_bounds[-1]]
        else:

```

```

        group = df_male[(df_male['孕妇 BMI'] > best_bounds[i - 1])
&
                        (df_male['孕妇 BMI'] <= best_bounds[i])]
    if group.empty:
        group_risk_means.append(np.nan)
        group_risk_stds.append(np.nan)
        best_weeks.append(np.nan)
        continue

    risk_mean, risk_std =
predict_prob_with_error_simulation(group)
    best_week, best_prob = best_week_for_group(group)
    group_risk_means.append(risk_mean)
    group_risk_stds.append(risk_std)
    best_weeks.append(best_week if best_week is not None else
np.nan)

    if best_week is not None:
        print(f"组 {i+1}: 样本 {len(group)}, 风险均值
{risk_mean:.4f}, "
              f"风险标准差 {risk_std:.4f}, 最佳孕周 {best_week:.2f}
周 (达标率 {best_prob:.3f})")
    else:
        print(f"组 {i+1}: 样本 {len(group)}, 风险均值
{risk_mean:.4f}, "
              f"风险标准差 {risk_std:.4f}, 无有效孕周点")

# ----- 风险均值 ± 标准差 + 最佳孕周图 -----

plt.figure(figsize=(10,6))
x_pos = np.arange(NUM_GROUPS)
group_labels = [f'组{i+1}' for i in range(NUM_GROUPS)]

# 使用渐变色 (从浅蓝到深蓝)
cmap = cm.get_cmap("coolwarm")
# 也可以换成 "viridis", "plasma", "coolwarm"
colors = [cmap(i / NUM_GROUPS) for i in range(NUM_GROUPS)]

bars = plt.bar(x_pos, group_risk_means, yerr=group_risk_stds,
               capsize=5, color=colors, label='风险均值 ± 标准差')

# 标注最佳孕周 (放在柱子内部, 白色字体)

```

```

    for i, (mean, std, week) in enumerate(zip(group_risk_means,
group_risk_stds, best_weeks)):
        if not np.isnan(week):
            plt.text(i, mean - 0.02, f'{week:.1f}周',
                    ha='center', va='top', fontsize=10, color='white',
fontweight='bold')

plt.xticks(x_pos, group_labels)
plt.ylabel('风险值')
plt.title('各组风险均值 ± 标准差及最佳孕周（考虑检测误差）')
plt.legend()
plt.tight_layout()
plt.savefig("图片/风险均值标准差_最佳孕周.png", dpi=300)
plt.show()

# ----- GA 收敛曲线 -----
df_log = pd.DataFrame(logbook)
df_log.to_excel("数据/GA 收敛过程.xlsx", index=False)

plt.figure()
plt.plot(df_log["gen"], df_log["min"], label="最优风险")
plt.plot(df_log["gen"], df_log["avg"], label="平均风险")
plt.xlabel("迭代代数")
plt.ylabel("风险值")
plt.legend()
plt.title("GA 收敛曲线")
plt.savefig("图片/GA 收敛曲线.png", dpi=300)
plt.show()

if __name__ == "__main__":
    main()

```

Python problem4

```

import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import train_test_split
from sklearn.metrics import roc_curve, roc_auc_score,
confusion_matrix
from sklearn.preprocessing import StandardScaler
import seaborn as sns
import os
plt.rcParams['font.sans-serif'] = ['SimHei'] # 使用黑体

```

```

plt.rcParams['axes.unicode_minus'] = False    # 解决负号显示问题
# 因变量（目标变量） - 请确认列名是否正确
DEPENDENT_VAR = '染色体的非整倍体'

# 自变量（特征变量）
INDEPENDENT_VARS = [
    '年龄', '身高', '体重', 'IVF 妊娠', '检测抽血次数', '检测孕周', '孕妇 BMI',
    '原始读段数', '在参考基因组上比对的比例', '重复读段的比例', '唯一比对的读段数',
    'GC 含量', '13 号染色体的 Z 值', '18 号染色体的 Z 值', '21 号染色体的 Z 值',
    'X 染色体的 Z 值', 'X 染色体浓度', '13 号染色体的 GC 含量', '18 号染色体的 GC 含量',
    '21 号染色体的 GC 含量', '被过滤掉读段数的比例', '怀孕次数', '生产次数'
]

def main():
    try:
        # 构造绝对路径
        base_dir = os.path.dirname(os.path.abspath(__file__))
        data_path = os.path.join(base_dir, '../数据/problem4.xlsx')
        roc_path = os.path.join(base_dir, '../图片/problem4_roc_curve.png')
        cm_path = os.path.join(base_dir, '../图片/problem4_confusion_matrix.png')
        coeff_path = os.path.join(base_dir, '../数据/problem4_coefficients.xlsx')

        # 读取数据
        data = pd.read_excel(data_path)
        print(f"成功加载数据，共 {len(data)} 行，{len(data.columns)} 列")

        # 检查因变量是否存在
        if DEPENDENT_VAR not in data.columns:
            raise ValueError(f"未找到因变量列: '{DEPENDENT_VAR}'")

        # 检查自变量是否存在
        missing_vars = [var for var in INDEPENDENT_VARS if var not in data.columns]
        if missing_vars:
            raise ValueError(f"数据集中缺少以下变量: {' '.join(missing_vars)}")

```

```
# 数据预处理
X = data[INDEPENDENT_VARS]
y = data[DEPENDENT_VAR]

# 缺失值处理
X = X.fillna(X.mean())
y = y.fillna(0) # 假设缺失的因变量为正常情况

# 特征标准化
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

# 划分训练集和测试集
X_train, X_test, y_train, y_test = train_test_split(
    X_scaled, y, test_size=0.3, random_state=42
)

# 逻辑回归模型
model = LogisticRegression(max_iter=1000)
model.fit(X_train, y_train)

# 预测
y_pred = model.predict(X_test)
y_prob = model.predict_proba(X_test)[: , 1]

# 计算性能指标
auc = roc_auc_score(y_test, y_prob)
fpr, tpr, thresholds = roc_curve(y_test, y_prob)

# 混淆矩阵
cm = confusion_matrix(y_test, y_pred)
tn, fp, fn, tp = cm.ravel()

# 计算灵敏度、特异性等指标
sensitivity = tp / (tp + fn)
specificity = tn / (tn + fp)
false_positive_rate = fp / (fp + tn)
false_negative_rate = fn / (fn + tp)

# 输出结果
print("\n=== 模型性能评估 ===")
print(f"AUC 值: {auc:.4f}")
print(f"灵敏度 (Sensitivity): {sensitivity:.4f}")
```

```

print(f"特异性 (Specificity): {specificity:.4f}")
print(f"假阳性率 (FPR): {false_positive_rate:.4f}")
print(f"假阴性率 (FNR): {false_negative_rate:.4f}")

# 绘制 ROC 曲线 (黄绿配色)
plt.figure()
plt.plot(fpr, tpr, color="#2ca02c", linewidth=2.2,
         label=f'ROC 曲线 (AUC = {auc:.2f})') # 深绿色
plt.plot([0, 1], [0, 1], linestyle="--", color="#ffe442",
linewidth=1.5) # 浅黄虚线
plt.xlabel('假阳性率 (FPR)', fontsize=12)
plt.ylabel('真阳性率 (TPR)', fontsize=12)
plt.title('ROC 曲线', fontsize=14)
plt.legend(loc="lower right", fontsize=11)
plt.grid(alpha=0.3, linestyle="--", color="gray") # 灰色淡网格
plt.savefig(roc_path, dpi=300, bbox_inches="tight")
plt.close()
print(f"\nROC 曲线已保存至: {roc_path}")

# 绘制混淆矩阵
plt.figure()
sns.heatmap(cm, annot=True, fmt='d', cmap="PuBu")
plt.xlabel('预测结果')
plt.ylabel('真实结果')
plt.title('混淆矩阵')
plt.savefig(cm_path)
plt.close()
print(f"混淆矩阵已保存至: {cm_path}")

# 保存回归系数
coeff_df = pd.DataFrame({
    '特征': INDEPENDENT_VARS,
    '回归系数': model.coef_[0]
})
coeff_df.to_excel(coeff_path, index=False)
print(f"回归系数已保存至: {coeff_path}")

print("\n 分析完成! ")

except Exception as e:
    print(f"\n 发生错误: {str(e)}")
    print("请检查以下可能原因: ")
    print("- 数据文件路径是否正确")
    print("- 数据集列名是否与代码一致")
    print("- 所需依赖库是否已安装")

```

```
if __name__ == "__main__":  
    print("=== 染色体非整倍体逻辑回归分析 ===")  
    print("=*60)  
    main()
```

Matlab linear regression problem1

```
% ----- 读取数据 -----  
load('nihe.mat'); % data 是你的矩阵  
  
% 假设 data 已经加载  
X = data(:, 1:end-1);  
y = data(:, end);  
  
%%  
% 稳健回归  
mdl = fitlm(X, y, 'RobustOpts','on');  
  
% 输出模型  
disp(mdl);  
  
% 系数  
disp('回归系数:');  
disp(mdl.Coefficients.Estimate);  
  
% 置信区间  
conf_intervals = coefCI(mdl);  
disp('95%置信区间:');  
disp(conf_intervals);  
  
% 拟合优度  
fprintf('R-square: %.4f\n', mdl.Rsquared.Ordinary);  
fprintf('Adjusted R-square: %.4f\n', mdl.Rsquared.Adjusted);  
fprintf('RMSE: %.4f\n', mdl.RMSE);  
  
% %% 普通逐步回归, 选择最优变量  
% mdl_step = stepwiselm(X, y);  
% % 不能加 RobustOpts  
%  
% disp('逐步回归模型:');  
% disp(mdl_step);  
% % 获取选择的变量  
% disp('最终选择的变量:');  
% disp(mdl_step.PredictorNames);
```



```
%  
% % 系数  
% disp('回归系数:');  
% disp mdl_step.Coefficients.Estimate);  
%  
% % 拟合优度  
% fprintf('R-square: %.4f\n', mdl_step.Rsquared.Ordinary);  
% fprintf('Adjusted R-square: %.4f\n', mdl_step.Rsquared.Adjusted);  
% fprintf('RMSE: %.4f\n', mdl_step.RMSE);
```